Antonin ALADENISE / Thelio DERVIEUX BUT SD - 1e année

SAÉ - Régression sur des données réelles

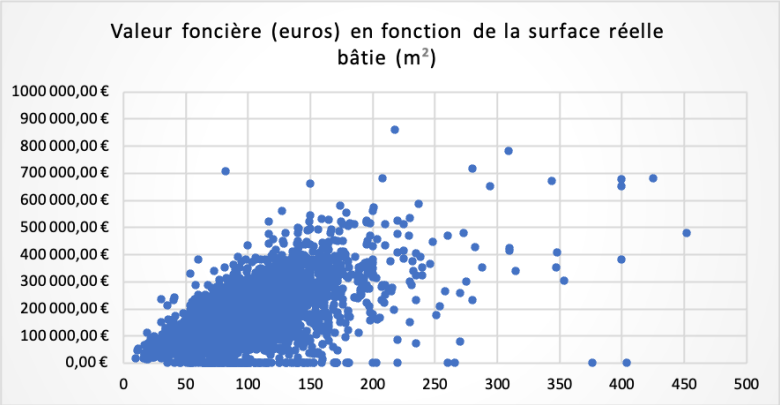
Modélisation des prix immobiliers dans l'agglomération niortaise

I. Introduction du projet

Ce rapport présente une démarche de modélisation du prix de vente de biens immobiliers (appartements et maisons) réalisés depuis 2021 dans les communes de la Communauté d'Agglomération du Niortais. L'objectif est de construire un modèle prédictif permettant d'estimer la valeur foncière de logements dont le prix de vente n'est pas connu.

Les données disponibles se répartissent en trois fichiers : un jeu d'entraînement (train.csv) contenant les transactions avec leurs prix de vente et variables descriptives, un jeu de test (test.csv) de structure identique permettant d'évaluer la performance du modèle, et un fichier de prédiction (to_predict.csv) regroupant 1 277 biens pour lesquels le prix de vente est à estimer.

La démarche adoptée s'articule en deux temps : une phase d'exploration et de segmentation des données, suivie d'une modélisation par Régression Linéaire Simple au sein de chaque segment. La surface réelle bâtie constitue la variable explicative principale, celle-ci présentant la corrélation la plus directe et la plus interprétable avec la valeur foncière.



II. Démarche de recherche et segmentation

La variable cible est la valeur foncière, exprimée en euros. L'exploration préliminaire met en évidence une distribution fortement asymétrique à droite, avec une concentration des transactions entre 80 000 € et 300 000 €, mais également des valeurs extrêmes atteignant plusieurs centaines de milliers d'euros. Cette hétérogénéité suggère que les données ne peuvent pas être traitées de manière homogène et qu'une segmentation préalable est nécessaire.

Deux variables explicatives ont été examinées en priorité : le type de bien (appartement ou maison) et la localisation géographique (commune et code postal). La surface réelle bâtie, après conversion en variable numérique, a été retenue comme base de régression principale dans les modèles de régression simple.

L'analyse croisée de la valeur foncière avec le type de bien montre des niveaux de prix structurellement différents entre appartements et maisons. Les maisons affichent en moyenne des prix nettement supérieurs, avec une plus grande dispersion liée à la variabilité des surfaces et des terrains. Les appartements présentent une relation plus linéaire avec la surface.

Moyenne	Valeur foncière	Surface réelle bâtie (m²)	Surface terrain (m²)	Nombre de pieces
Maison	180 806,96 €	99,84	548,70	4
Appartement	100 116,78 €	53,59	286,00	2

La dimension géographique révèle également des disparités importantes. Niort, pôle urbain dominant de la Communauté d'Agglomération du Niortais, concentre le volume le plus important de transactions et affiche des prix au m² plus élevés. Chauray, commune résidentielle très prisée, présente un marché différent, notamment pour les maisons (forte demande, offre limitée). Les autres communes forment un marché rural plus hétérogène, avec des prix globalement inférieurs.

Les deux critères de segmentation retenus sont présentés dans le tableau ci-dessous.

Critère	Modalités	Justification
Commune	Niort / Chauray / Autres communes	Niort est le pôle urbain central ; Chauray est une commune résidentielle dynamique limitrophe ; les autres communes présentent un marché rural distinct.
Type de local	Appartement / Maison	Les appartements et les maisons obéissent à des logiques de prix très différentes (densité, terrain, charges de copropriété).

III. Modèles retenus par segment

Pour chaque segment, un modèle de Régression Linéaire Simple est estimé, reliant la valeur foncière (Y) à la surface réelle bâtie (X) selon l'équation :

Valeur foncière = a × Surface réelle bâtie + b

Les coefficients a et b sont calculés par la méthode des moindres carrés ordinaires, implémentée manuellement en R via les formules de la covariance et de la variance.

Le tableau ci-dessous synthétise les six segments et la forme du modèle appliqué à chacun.

Segment	Commune	Type de local	Modèle retenu
1	Chauray	Appartement	Linéaire simple
2	Chauray	Maison	Linéaire simple
3	Niort	Appartement	Linéaire simple
4	Niort	Maison	Linéaire simple
5	Autres communes	Appartement	Linéaire simple
6	Autres communes	Maison	Linéaire simple

Les modèles ont été appliqués aux 1 277 biens du fichier to_predict.csv. Chaque bien se voit affecter son segment en fonction de sa commune et de son type puis sa valeur foncière est prédite par l'équation de régression. Les prédictions générées sont exportées dans le fichier prediction.csv.

IV. Conclusion

La démarche de segmentation retenue, croisant le type de bien par commune permet de construire des modèles adaptés aux sous-marchés immobiliers de la Communauté d'Agglomération du Niortais. L'approche par Régression Linéaire Simple offre l'avantage de la lisibilité et de l'interprétabilité : chaque coefficient traduit une réalité économique directement intelligible.

Mais plusieurs points méritent d'être soulignés. Premièrement, la surface réelle bâtie, bien que pertinente, ne représente qu'une partie de la variabilité des prix : l'état du bien, la présence d'un jardin ou d'un garage, l'étage, l'année de construction, ou encore le niveau d'équipements de la commune sont des facteurs ignorés. Deuxièmement, la Régression Linéaire Simple suppose une relation linéaire entre surface et prix, hypothèse qui peut être moins fiable pour les très grandes ou très petites surfaces. Troisièmement, certains segments comme le premier segment (Chauray / Appartement) peuvent comporter peu d'observations, ce qui fragilise la fiabilité des coefficients estimés.