Modélisation des prix immobiliers dans l'agglomération niortaise

Contexte

Vous disposez de données sur les transactions immobilières (appartements et maisons) réalisées depuis 2021 dans les communes de la Communauté d'Agglomération du Niortais. Ces données sont réparties en trois fichiers :

- `train.csv` : contient un échantillon de logements avec leur prix de vente et des variables descriptives. Il sera utiliser pour élaborer votre modèle.
- `test.csv` : contient un autre échantillon de logements. Sa structure est identique à `train.csv`. Vous pourrez l'utiliser pour évaluer la performance de votre modèle.
- `to_predict.csv` : contient les mêmes variables que `train.csv` et `test.csv`, mais **sans le prix de vente**. Votre objectif est de prédire ces prix manquants.

Travail à effectuer

☞ Exploration et segmentation

Explorer les données pour identifier des tendances ou des groupes homogènes (par exemple, selon le type de logement ou la localisation). L'objectif est d'arriver à une segmentation préalable à la modélisation.

> ✎ *Cette partie peut être effectuée avec les outils de votre choix : Excel, Tableau, PowerBi...*

☞ Modélisation

Pour chaque segment, utiliser la Régression Linéaire Simple (RLS) pour modéliser le prix de vente.

Vous pouvez tester des transformations de variables (modèles exponentiel, puissance ou logarithme) pour améliorer les ajustements.

> ✱ *Le fichier `test.csv` vous permet d'évaluer la qualité de votre modèle à l'aide du coefficient de détermination ou de la Somme des Carrés des Résidus.*

☞ Prédiction et interprétation

Appliquer votre modèle pour prédire les prix dans `to_predict.csv`.

> ✎ *Ces deux parties devront être réalisées en R natif : pas de librairie externe. L'utilisation des fonctions `lm()` et `predict()` est également interdit!*

Documents à remettre

☞ Un texte bien structuré (environ deux pages hors illustrations) avec :

- Une introduction présentant le projet ;
- Votre démarche de recherche pour élaborer votre segmentation. Cette étape passe par l'étude de la variable cible et le croisement de cette variable avec les différentes variables explicatives. Vous pouvez enrichir votre texte avec des graphiques qui vous ont été utiles.
- L'exposition claire du modèle retenu pour chaque segment ;
- Une conclusion dans laquelle vous pourrez notamment apporter un regard critique sur le modèle élaboré.

☞ Un fichier nommé `prediction.csv` au format CSV2 contenant 2 variables : la variable `id` du jeu test et une variable `Valeur.fonciere` contenant vos prédictions ;

☞ Le code R ayant permis de générer ce fichier à partir des 2 fichiers fournis (`train.csv` et `to_predict.csv`). Ce code doit commencer par l'importation des fichiers train et test et se terminer par l'export du fichier `prediction.csv`.

> ❋ *Vous veillerez à respecter scrupuleusement ces instructions : pas d'accent, respect de la casse, format CSV2...*

Éléments concernant l'évaluation

Voici les principaux critères d'évaluation :

- La méthodologie utilisée pour élaborer le modèle et la profondeur des recherches menées
- La complexité du modèle retenu
- La qualité et la clarté de votre rapport
- La clarté et l'efficacité de votre code R
- La précision de vos prédictions qui se fera au moyen de la métrique « somme des carrés des résidus ». Un classement des meilleurs prédictions sera effectué.

Environ la moitié des points est attribuée au rapport.